

Нормальное распределение

Винни-Пух 2026-09-11

Нормальное распределение

От аксиом Гершеля-Максвелла к дифференциальному уравнению

Стандартный учебник по теории вероятностей, начинает главу про нормальное распределение с определения,

Definition 1 (Классическое определение нормального распределения)

Случайная величина имеет нормальное распределение с ожиданием μ и дисперсией σ^2 , если её функция плотности имеет вид

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \quad (1)$$

У любого небезразличного читателя сразу возникнет вопрос: шо? откуда тут взялись π , экспонента и корень? Поэтому давайте сейчас забудем эту формулу и попробуем переоткрыть её.

Представим себе, что мы поймали одну из молекул кислорода, летающую в закрытой комнате. Для простоты изложения будем считать, что комната плоская и у пойманной молекулы всего две компоненты скорости, (X, Y) . Что разумно предположить про закон распределения этого вектора?

Комната закрыта, ветра нет, поэтому разумно предположить, что молекулы движутся случайно, не предпочитая ни одно из направлений. Это означает, что при повороте вектора (X, Y) на любой фиксированный угол закон распределения вектора не изменяется.

Кроме того, разумно предположить, что компоненты скорости независимы: если мы знаем, что молекула летит к югу по оси север-юг, это не несёт нам информации о направлении молекулы по оси запад-восток.

Эти две предпосылки назовём аксиомами Гершеля-Максвелла.

Definition 2 (Аксиомы Гершеля-Максвелла)

Говорят, что компоненты вектора (X, Y) имеют нормальное распределение, симметричное относительно нуля, если вектор удовлетворяет двум аксиомам:

1. Закон распределения вектора (X, Y) инвариантен к повороту на любой фиксированный угол относительно точки $(0, 0)$.
2. Компоненты вектора независимы.



Оказывается, этих двух предпосылок достаточно, чтобы получить функцию плотности вектора (X, Y) . Для начала попробуем простые следствия.

Если повернуть вектор (X, Y) на 180° , то он превратиться в вектор $(-X, -Y)$. Следовательно, закон распределения величины X и величины $(-X)$ одинаковый, $X \sim -X$.

Если повернуть вектор (X, Y) на 90° против часовой стрелке, то он превратиться в вектор $(-Y, X)$. Отсюда мы получаем ещё пару совпадений законов распределения, $X \sim -Y$ и $Y \sim X$.

todo: тут картинка

Предположим дополнительно, что у вектора (X, Y) есть совместная функция плотности $f(x, y)$. Строго говоря, существование плотности тоже можно вывести из аксиом Гершеля-Максвелла, но я не знаю как это изложить легко и доступно¹.

¹ todo ссылка

Немного заабызим букву f и будем использовать её как для совместной плотности пары величин, $f(x, y)$, так и для индивидуальной плотности $f(x)$. В силу одинаковости распределения компонент скорости X и Y и их независимости,

$$f(x) \cdot f(y) = f(x, y).$$

Прологарифмируем,

$$\ln f(x) + \ln f(y) = \ln f(x, y).$$

Для распределения инвариантного к повороту ни левая, ни правая части не зависят от угла φ . Продифференцируем обе части по углу φ ,

$$\frac{f'(x)}{f(x)} \cdot \frac{dx}{d\varphi} + \frac{f'(y)}{f(y)} \cdot \frac{dy}{d\varphi} = 0.$$

Или

$$\frac{f'(x)}{f(x)} \cdot (-y) + \frac{f'(y)}{f(y)} \cdot x = 0.$$

Разнесём x и y по разным частям уравнения

$$\frac{f'(x)}{f(x)} \cdot y = \frac{f'(y)}{f(y)} \cdot x.$$

Или

$$\frac{yf(y)}{f'(y)} = \frac{xf(x)}{f'(x)}.$$

Это не уравнение, связывающее величины x и y , а тождество, верное при любых x и y . Левая часть тождества зависит только от x , правая — только от y , следовательно, тождество возможно, только если обе части равны константе.

$$\frac{xf(x)}{f'(x)} = \text{const.}$$

Сначала задумаемся о знаке константы в правой части. Если константа положительна, то при $x > 0$ производная $f'(x) > 0$ и функция плотности $f(x)$ возрастает, а при $x < 0$, наоборот, $f'(x) < 0$ и график $f(x)$ убывает. Гипотетически, при положительной константе функция $f(x)$ выглядела бы примерно так,

todo: тут гипотетический график

Конечно, такой график для функции плотности невозможен в силу того, что площадь под функцией плотности должна равняться единице, $\int_{-\infty}^{+\infty} f(x)dx = 1$. Следовательно, константа в правой части тождества отрицательная, а график плотности убывает справа от нуля и возрастает слева.

todo: тут верная картинка

Заметим, что при $x \rightarrow +\infty$ или при $x \rightarrow -\infty$ функция плотности должна убывать до нуля, иначе мы не получим единичную площадь под плотностью.

todo: на полях ещё одна гипотетическая картинка, где плотность убывает не до нуля.

Теперь задумаемся о единицах измерения константы. Величина x — это скорость молекулы по горизонтали. Будем измерять её в метрах в секунду. Маленькая разница dx тогда тоже измеряется в метрах в секунду. Вероятность попадания в малый отрезок выражается через функцию плотности,

$$\mathbb{P}(X \in [x, x + dx]) \stackrel{\heartsuit}{=} f(x) \cdot dx.$$

Вероятность не имеет единиц измерения, dx измеряется в метрах в секунду, поэтому функция плотности $f(x)$ измеряется в обратных единицах измерения по сравнению с исходной величиной x , в нашем случае плотность измеряется в $(\text{м/сек})^{-1}$. Производная $f'(x) = \frac{df(x)}{dx}$ измеряется в $(\text{м/сек})^{-2}$.

Следовательно, дробь $\frac{xf(x)}{f'(x)}$ равна отрицательной константе с размерностью $(\text{м/сек})^2$. Поэтому давайте обозначим константу const в правой части как $-\sigma^2$:

$$\frac{xf(x)}{f'(x)} = -\sigma^2.$$

Это опорное дифференциальное уравнение. Этому уравнению и равенства площади под плотностью единице, $\int_{-\infty}^{+\infty} f(x)dx = 1$, достаточно, чтобы найти функцию плотности в явном виде.

От дифференциального уравнения к свойствам

Для решения уравнения заметим, что дробь $f'(x)/f(x)$ можно записать как $(\ln f(x))'$. Кстати, производная $f'(x)$ измеряет скорость изменения функции, а дробь $f'(x)/f(x)$ измеряет скорость изменения в функции в долях (или в процентах) от текущего значения функции $f(x)$.²

$$\frac{x}{(\ln f(x))'} = -\sigma^2.$$

Выражаем производную логарифма плотности,

$$(\ln f(x))' = -\frac{x}{\sigma^2}.$$

Восстанавливаем логарифм плотности

$$\ln f(x) = c - \frac{x^2}{2\sigma^2}$$

и саму функцию плотности

$$f(x) = d \cdot \exp\left(-\frac{x^2}{2\sigma^2}\right).$$

Совместная плотность вектора (X, Y) равна произведению индивидуальных,

$$f(x, y) = f(x) \cdot f(y) = d^2 \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right).$$

Процитируем полностью текст из работы Гершеля³. Это просто фантастика по современным меркам. Он получает ту же формулу с суммой квадратов x и y внутри экспоненты обходясь словами!

We set out from three postulates. 1st, that the probability of a compound event, or of the concurrence of two or more independent simple events, is the product of the probabilities of its constituents considered singly; 2dly, that there exists a relation or numerical law of connexion (at present unknown) between the amount of error committed in any numerical determination and the probability of committing it, such that the greater the error the less its probability, according to some regular LAW of progression, **which must necessarily be general and apply alike to all cases, since the causes of error are supposed alike unknown in all; and it is on this ignorance, and not upon any peculiarity in cases, that the idea of probability in the abstract is founded;** 3dly, that the errors are equally probable if equal in numerical amount, whether in excess, or in defect of, or in any way beside the truth. This latter postulate necessitates our assuming the function of probability to be what

² Например, если $f'(x) = 0.01$, то при единичном изменении x плотность вырастет примерно на 0.01, а если $f'(x)/f(x) = 0.01$, то при единичном изменении x плотность вырастет примерно на 1%.

³ [1] J. F. W. Herschel, "On the Theory of Probabilities," *Journal of the Institute of Actuaries and Assurance Magazine*, vol. 15, pp. 179–218, 1869, [Online]. Available: https://www.informationphilosopher.com/solutions/scientists/quetetlet/Herschel_Quetelet_Probabilities.pdf

is called in mathematical language **an even function, or a function of the square of the error**, so as to be alike for positive and negative values; and the postulate itself is nothing more than the expression of our state of **complete ignorance** of the causes of error, and their mode of action. To determine the form of this function, we will consider a case in which the relations of space are concerned.

Suppose a ball dropped from a given height, with the intention that it shall fall on a given mark. Fall as it may, its deviation from the mark is **error**, and the probability of that error is the unknown function of its square, **i. e.** of the sum of the squares of its deviations in any two rectangular directions. Now, the probability of any deviation depending solely on its **magnitude**, and not on its direction, it follows that the probability of each of these rectangular deviations must be the same function of its square. And since the observed oblique deviation is equivalent to the two rectangular ones, supposed concurrent, and which are essentially independent of one another, and is, therefore, a compound event of which they are the simple independent constituents, therefore its probability will be the product of their separate probabilities. Thus the form of our unknown function comes to be determined from this condition, viz., that the product of such functions of two independent elements is equal to the same function of their sum. But it is shown in every work on algebra that this property is the peculiar characteristic of, and belongs only to, the exponential or antilogarithmic function. This, then, is the function of the square of the error, which expresses the probability of committing that error. That probability decreases, therefore, in geometrical progression, as the square of the error increases in arithmetical. And hence it further follows, that the probability of successively committing any given system of errors on repetition of the trial, being, by postulate I., the product of their separate probabilities, must be expressed by the same exponential function of the sum of their squares however numerous, and is, therefore, a maximum when that sum is a minimum.

Интересно заметить, что с точки зрения Гершеля, формула $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$ для независимых событий A и B — это первая аксиома, которую надо явно проговорить.

Немного забегая вперёд скажем, что из условия нормировки $\int_{-\infty}^{+\infty} f(x)dx = 1$ следует, что константы в общем решении дифференциального уравнения равны

$$c = \ln f(0) = -\frac{\ln \pi + \ln(\sigma^2)}{2} \quad \text{и} \quad d = f(0) = \frac{1}{\sqrt{2\pi\sigma^2}},$$

а функция плотности, соответственно, равна

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2}\sigma^2\right).$$

Однако оказывается, что полезные свойства распределения гораздо проще установить исходя из аксиом или дифференциального уравнения, а не из явного вида плотности!

Найдём ожидания $\mathbb{E}(X)$ и $\mathbb{E}(|X|)$, дисперсию $\text{Var}(X)$, точки перегиба функции плотности $f(x)$ и нарисуете график функции плотности $f(x)$.

Прежде всего, заметим, что график плотности должен быть симметричен относительно вертикальной оси $x = 0$. Это следует из предпосылки об инвариантности распределения вектора (X, Y) при повороте. Поворачиваясь на 180° , мы превращаем измеряемую скорость X в скорость $-X$, поэтому функция плотности у величины X и у величины $(-X)$ должна быть одинаковая. Из одинакового закона распределения величин X и $-X$ математическое ожидание $\mathbb{E}(X)$ должно равняться нулю, либо не существовать. Мы уже знакомы [todo: проверить порядок изложения] с распределением Коши, у которого функция плотности симметрична относительно нуля, однако ожидание не существует. Чтобы выяснить, существует ли ожидание в данном случае, воспользуемся формулой для ожидания и дифференциальным уравнением:

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} x f(x) dx = -\sigma^2 \int_{-\infty}^{+\infty} f'(x) dx = -\sigma^2 (f(+\infty) - f(-\infty)).$$

Мы уже знаем, что $f(+\infty) = f(-\infty) = 0$, следовательно, ожидание существует и равно $\mathbb{E}(X) = 0$.

Найдём дисперсию! Для этого снова воспользуемся дифференциальным уравнением:

$$\text{Var}(X) = \mathbb{E}(X^2) - (\mathbb{E}X)^2 = \mathbb{E}(X^2) = \int_{-\infty}^{+\infty} x^2 f(x) dx = -\sigma^2 \int_{-\infty}^{+\infty} x f'(x) dx.$$

Возьмём требуемый интеграл по частям:

$$\int_{-\infty}^{+\infty} x f'(x) dx = [x f(x)]_{-\infty}^{+\infty} - \int_{-\infty}^{+\infty} f(x) dx.$$

Уменьшаемое $[x f(x)]_{-\infty}^{+\infty}$ равно нулю в силу того, что экспонента растёт быстрее любого многочлена,

$$\lim_{x \rightarrow \infty} x f(x) = \lim_{x \rightarrow \infty} \frac{x}{d \cdot \exp\left(\frac{x^2}{2} \sigma^2\right)} = 0.$$

Вычитаемое $\int_{-\infty}^{+\infty} f(x) dx$ равно единице как площадь под функцией плотности. Мы можем завершить нахождение дисперсии

$$\text{Var}(X) = -\sigma^2 \int_{-\infty}^{+\infty} x f'(x) dx = -\sigma^2 (0 - 1) = \sigma^2.$$

Теперь с полным правом можем дать определение нормальной случайной величины.

Definition 1 (Нормальное центрированное распределение)

Случайная величина X , чья функция плотности $f(x)$ удовлетворяет дифференциальному уравнению

$$\frac{xf(x)}{f'(x)} = -\sigma^2, \quad (2)$$

называется нормальной случайной величиной с ожиданием 0 и дисперсией σ^2 и обозначается $\text{Norm}(0, \sigma^2)$.



Найдём точки перегиба функции плотности, для этого выразим производную плотности из определения,

$$f'(x) = -\frac{xf(x)}{\sigma^2},$$

продифференцируем её ещё раз и снова воспользуемся дифференциальным уравнением,

$$f''(x) = -\frac{f(x) + xf'(x)}{\sigma^2} = -\frac{f(x) + x^2 \frac{f(x)}{\sigma^2}}{\sigma^2}.$$

В точке перегиба $f''(x) = 0$, что возможно только при $x = \pm\sigma$.

Найдём ожидание модулю скорости, воспользовавшись симметрией плотности,

$$\mathbb{E}(|X|) = \int_{-\infty}^{+\infty} |x|f(x)dx = 2 \int_0^{+\infty} xf(x)dx = -2\sigma^2 \int_0^{+\infty} f'(x)dx = -2\sigma^2(f(+\infty) - f(0)).$$

На бесконечности функция плотности обращается в ноль, поэтому среднее значение модуля скорости равно

$$\mathbb{E}(|X|) = 2\sigma^2 f(0).$$

Используем данное нами ранее обещание, что константа в решении дифференциального уравнения равна

$$d = f(0) = \frac{1}{\sqrt{2\pi\sigma^2}},$$

мы получаем, что средний модуль скорости молекулы равен

$$\mathbb{E}(|X|) = 2\sigma^2 f(0) = \sigma \sqrt{\frac{2}{\pi}} \approx 0.80\sigma.$$

Проговорим интерпретацию словами. Константа σ^2 — это дисперсия скорости молекулы, кроме того, σ — это примерно 125% от среднего модуля скорости.

При нахождении ожиданий мы уже пару раз пользовались приятной связкой дифференциального уравнения и интегрирования по частям. В силу дифференциального уравнения можно перейти от произведения $xf(x)$ к производной $f'(x)$, к

которой удобно применять формулу интегрирования по частям. Давайте оформим эту связку в виде леммы.

К примеру мы хотим найти ожидание $\mathbb{E}(X \cdot h(X))$. Начнём его искать:

$$\mathbb{E}(h(X)) = \int_{-\infty}^{+\infty} xh(x)f(x)dx = -\sigma^2 \int_{-\infty}^{+\infty} h(x)f'(x)dx.$$

Если функция $h(x)$ не слишком быстро растёт⁴, а именно, если

$$\lim_{x \rightarrow -\infty} h(x)f(x) = 0 \quad \text{и} \quad \lim_{x \rightarrow +\infty} h(x)f(x) = 0,$$

то формула интегрирования по частям теряет первое слагаемое $[h(x)f(x)]_{-\infty}^{+\infty}$ и упрощается до

$$\int_{-\infty}^{+\infty} h(x)f'(x)dx = 0 - \int_{-\infty}^{+\infty} h'(x)f(x)dx = -\mathbb{E}(h'(X)).$$

Мы получили лемму Стейна.

Лемма 2 (“Лемма Стейна”)

Если величина X имеет нормальное распределение $\text{Norm}(0, \sigma^2)$ и функция $h(x)$ не слишком быстро растёт на плюс-минус бесконечности, а именно, если⁵

$$\lim_{x \rightarrow +\infty} h(x)f(x) = \lim_{x \rightarrow -\infty} h(x)f(x) = 0, \text{ то}$$

$$\mathbb{E}(X \cdot h(X)) = \sigma^2 \mathbb{E}(h'(X)). \quad (3)$$

⁴ Например, подойдут любые многочлены, произведения многочленов с синусами или косинусами...

⁵ Под $f(x)$ мы подразумеваем функцию плотности.

Например, по лемме Стейна можно очень быстро посчитать ожидание и дисперсию, если вдруг кто-то успел их забыть :)

$$\mathbb{E}(X) = \mathbb{E}(X \cdot 1) = \sigma^2 \mathbb{E}(1') = \mathbb{E}(0) = 0.$$

И, дисперсия,

$$\mathbb{E}(X^2) = \mathbb{E}(X \cdot X) = \sigma^2 \mathbb{E}(X') = \sigma^2 \mathbb{E}(1) = \sigma^2.$$

А если серьёзно, то можно найти ожидание любого момента для нормальной $\text{Norm}(0, \sigma^2)$ величины. Третий момент,

$$\mathbb{E}(X^3) = \mathbb{E}(X \cdot X^2) = \sigma^2 \mathbb{E}(2X) = 0.$$

Четвёртый момент,

$$\mathbb{E}(X^4) = \mathbb{E}(X \cdot X^3) = \sigma^2 \mathbb{E}(3X^2) = 3\sigma^4.$$

Нетрудно заметить, что удаление одного сомножителя X у X^n и последующее взятие производной снижает степень у X на два и выносит вперёд сомножитель $(n-1)\sigma^2$.

$$\mathbb{E}(X^n) = \mathbb{E}(X \cdot X^{n-1}) = \sigma^2 \mathbb{E}((n-1)X^{n-2}) = (n-1)\sigma^2 \mathbb{E}(X^{n-2}).$$

Следовательно, для любой чётной степени $n = 2k$ получаем

$$\mathbb{E}(X^{2k}) = (2k-1)(2k-3)\dots 3 \cdot 1 \cdot \sigma^{2k},$$

что компактно записывают с помощью двойного факториала,

$$\mathbb{E}(X^{2k}) = (2k-1)!! \cdot \sigma^{2k}.$$

А для нечётных степеней $\mathbb{E}(X^{2k-1}) = 0$ в силу одинаковости распределения X и $-X$.

Найдём производящую функцию для нормального распределения. По определению производящей функции,

$$g(t) = \mathbb{E}(\exp(tX)).$$

Перед нами ну почти лемма Стейна, не хватает только величины X внутри ожидания, давайте этого кукушонка туда подбросим! Применим трюк Фейнмана и возьмём слева и справа производную по t .

$$g'(t) = \mathbb{E}(\exp(tX) \cdot X).$$

Следите за руками, теперь мы будем применять лемму Стейна, а в ней фигурирует производная по X !

$$g'(t) = \mathbb{E}(\exp(tX) \cdot X) = \sigma^2 \mathbb{E}\left(d \frac{\exp(tX)}{d} X\right) = \sigma^2 \mathbb{E}(\exp(tX)t) = t\sigma^2 g(t).$$

Отсюда, мы получаем дифференциальное уравнение на производящую функцию $g(t)$,

$$\frac{g'(t)}{g(t)} = t\sigma^2 \text{ с начальным условием } g(0) = 1.$$

Да это же брат-близнец дифференциального уравнение для функции плотности,

$$\frac{f'(x)}{f(x)} = -x \frac{1}{\sigma^2} \text{ с начальным условием } f(0) = \frac{1}{\sqrt{2\pi\sigma^2}}.$$

Только константа σ^2 не в знаменателе теперь, а в числителе, да знак минус исчез. Поэтому, совершенно аналогично, сделав ту же замену $\frac{g'(t)}{g(t)} = (\ln g(t))'$ можно явно найти производящую моменты функцию,

$$g(t) = \exp\left(\sigma^2 \frac{t^2}{2}\right).$$

Разложим нашу функцию $g(t)$ в ряд Тейлора, чтобы ещё одним путём увидеть моменты $\mathbb{E}(X^k)$:

$$g(t) = 1 + 0 \cdot t + \frac{\sigma^2}{2} t^2 + 0 \cdot t^3 + \left(\frac{\sigma^2}{2}\right)^2 \frac{1}{2!} t^4 + 0 \cdot t^5 + \left(\frac{\sigma^2}{2}\right)^3 \frac{1}{3!} t^6 + \dots$$

Напомним, что любая производящая моменты функция раскладывается в ряд как

$$g(t) = 1 + \mathbb{E}(X) \cdot t + \mathbb{E}(X^2) \cdot \frac{1}{2!} t^2 + \mathbb{E}(X^3) \cdot \frac{1}{3!} t^3 + \mathbb{E}(X^4) \cdot \frac{1}{4!} t^4 + \mathbb{E}(X^5) \cdot \frac{1}{5!} t^5 + \mathbb{E}(X^6) \cdot \frac{1}{6!} t^6 + \dots$$

И мы снова видим, что все нечётные моменты для нормальной $\text{Norm}(0, \sigma^2)$ величины равны нулю, например, $\mathbb{E}(X^5) = 0$, а нечётные — положительны. Посмотрим, например, на шестой момент,

$$\mathbb{E}(X^6) = \frac{6!}{2^3 \cdot 3!} \sigma^6 = \frac{6 \cdot 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1}{2 \cdot 2 \cdot 2 \cdot 3 \cdot 2 \cdot 1} \sigma^6.$$

Из факториала $6!$ в числителе знаменатель сократит все чётные числа, и после сокращения останется $5!! = 5 \cdot 3 \cdot 1$, то есть,

$$\mathbb{E}(X^6) = 5!! \sigma^6.$$

В общем случае, как и через лемму Стейна, получаем $\mathbb{E}(X^{2k}) = (2k-1)!! \sigma^k$.

Естественно, если сместить функцию вправо на μ , то мы сохраним дисперсию, а математическое ожидание новой величины окажется равным μ .

Определение. Случайная величина X , чья функция плотности $f(x)$ удовлетворяет дифференциальному уравнению

$$\frac{(x - \mu)f(x - \mu)}{f'(x - \mu)} = -\sigma^2,$$

называется нормальной случайной величиной с ожиданием μ и дисперсией σ^2 и обозначается $X \sim \text{Norm}(\mu, \sigma^2)$.

Чтобы быть в числе благородных донов остаётся доказать, что из условия единичной площади под функцией плотности следует, что нормировочная константа равна именно $1/\sqrt{2\pi\sigma^2}$.

Лог функции плотности убывает со всё растущей скоростью. Следовательно, плотность убывает в ноль. Плотность помножить на любой многочлен убывает в ноль.

График, иллюстрирующий быстроту убывания, парабола под графиком плотности, шаг по вертикали $2 \ln(2) \approx 1.4$.

Нахождение константы: графическое свойство экспоненты: площадь и длина тени касательной. Принцип Мамикона.

Свойства нормального распределения!

Из геометрии следует: при масштабировании предпосылки сохраняются. Любая линейная комбинация нормальных тоже нормальна.

Вывод, что $X^2 + Y^2$ имеет экспоненциальное распределение с помощью о-малых и вероятности попасть в кольцо площади $\pi \cdot dq$.

Связь экспоненциальным распределением.

$$Q = R^2 = X^2 + Y^2$$

$$\mathbb{P}(Q \in [q; q + dq]) = f(x, y) \cdot \pi \cdot dq = f(\sqrt{Q}, 0) \cdot \pi \cdot dq = \frac{1}{2} \exp\left(-\frac{q}{2}\right) \cdot dq$$

$$X^2 + Y^2 \sim \text{Expon}(\lambda = \frac{1}{2})$$

Многомерное нормальное распределение

Хитрый лис Иссерлис

todo: картинка хитрой лисы?

Рассмотрим многомерный нормальный вектор $Y \sim \text{Norm}(m, C)$.

Давайте научимся находить математические ожидания от произвольных одночленов. Например, чему равно ожидание $\mathbb{E}(Y_1 Y_2 Y_3 Y_4)$?

Для удобства явно выпишем вектор ожиданий m и ковариационную матрицу C :

$$Y \sim \text{Norm} \left(\begin{pmatrix} m_1 \\ m_2 \\ m_3 \\ m_4 \end{pmatrix}, \begin{pmatrix} c_{11} & c_{12} & c_{13} & c_{14} \\ c_{21} & c_{22} & c_{23} & c_{24} \\ c_{31} & c_{32} & c_{33} & c_{34} \\ c_{41} & c_{42} & c_{43} & c_{44} \end{pmatrix} \right).$$

Начнём с самых простых одночленов! Чему равно ожидание $\mathbb{E}(Y_1)$?

Здесь ответ простой, и нормальность распределения вовсе не нужна, мы сами ввели обозначение

$$\mathbb{E}(Y_1) = m_1.$$

Второй шаг. Чему равно ожидание $\mathbb{E}(Y_1 Y_2)$?

В силу определения ковариации, $\text{Cov}(Y_1, Y_2) = \mathbb{E}(Y_1 Y_2) - \mathbb{E}(Y_1)\mathbb{E}(Y_2)$, получаем формулу

$$\mathbb{E}(Y_1 Y_2) = m_1 m_2 + c_{12}.$$

Нормальность пока, по-прежнему, не использовали. Эта формула верна для произвольно распределённых величин с $\mathbb{E}(Y_i) = m_i$ и $\text{Cov}(Y_i, Y_j) = c_{ij}$.

Третий шаг. Чему равно ожидание $\mathbb{E}(Y_1 Y_2 Y_3)$?

Для удобства центрируем величины, $Y_i = m_i + X_i$, у вектора $X = (X_1, X_2, X_3, X_4)$ будут нулевые математические ожидания и исходная ковариационная матрица,

$$X \sim \text{Norm} \left(\begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} c_{11} & c_{12} & c_{13} & c_{14} \\ c_{21} & c_{22} & c_{23} & c_{24} \\ c_{31} & c_{32} & c_{33} & c_{34} \\ c_{41} & c_{42} & c_{43} & c_{44} \end{pmatrix} \right).$$

Используем центрирование и раскрываем скобки!

$$\begin{aligned} \mathbb{E}(Y_1 Y_2 Y_3) &= \mathbb{E}((m_1 + X_1)(m_2 + X_2)(m_3 + X_3)) = \\ &= m_1 \mathbb{E}(X_2 X_3) + m_2 \mathbb{E}(X_1 X_3) + m_3 \mathbb{E}(X_1 X_2) + m_1 m_2 \mathbb{E}(X_3) + m_1 \mathbb{E}(X_2) m_3 + \mathbb{E}(X_1) m_2 m_3 + \\ &\quad + m_1 m_2 m_3 + \mathbb{E}(X_1 X_2 X_3). \end{aligned}$$

В силу центрированности величин X_i с ними проще: $\mathbb{E}(X_i) = 0$ и $\mathbb{E}(X_i X_j) = c_{ij}$. Упрощаем наше выражение:

$$\mathbb{E}(Y_1 Y_2 Y_3) = m_1 c_{23} + m_2 c_{13} + m_3 c_{12} + m_1 m_2 m_3 + \mathbb{E}(X_1 X_2 X_3).$$

Теперь воспользуемся симметрией! todo: ходулочник или цветок в воде с отражением Повернём вектор X на 180° , получим вектор $W = (-X_1, -X_2, -X_3)$. У вектора W снова будут нулевые ожидания и та же исходная ковариационная матрица в силу того, что $\text{Cov}(-X_i, -X_j) = \text{Cov}(X_i, X_j)$,

$$W \sim \text{Norm} \left(\begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} c_{11} & c_{12} & c_{13} & c_{14} \\ c_{21} & c_{22} & c_{23} & c_{24} \\ c_{31} & c_{32} & c_{33} & c_{34} \\ c_{41} & c_{42} & c_{43} & c_{44} \end{pmatrix} \right).$$

С одной стороны, мы видим, что векторы X и W распределены одинаково, $W \sim X$, поэтому

$$\mathbb{E}(W_1 W_2 W_3) = \mathbb{E}(X_1 X_2 X_3).$$

С другой стороны,

$$\mathbb{E}(W_1 W_2 W_3) = \mathbb{E}((-X_1)(-X_2)(-X_3)) = \mathbb{E}(-X_1 X_2 X_3) = -\mathbb{E}(X_1 X_2 X_3).$$

Одновременно эти два равенства возможны, только если $\mathbb{E}(X_1 X_2 X_3) = 0$.

Ура, мы получили ожидаемое значение для произведения трёх игреков:

$$\mathbb{E}(Y_1 Y_2 Y_3) = m_1 c_{23} + m_2 c_{13} + m_3 c_{12} + m_1 m_2 m_3.$$

Здесь мы уже пользовались симметричностью нормального распределения.

Упражнение. Придумайте вектор с ожиданиями $\mathbb{E}(Y_i) = m_i$ и ковариацией $\text{Cov}(Y_i, Y_j) = c_{ij}$, для которого формула $\mathbb{E}(Y_1 Y_2 Y_3) = m_1 c_{23} + m_2 c_{13} + m_3 c_{12} + m_1 m_2 m_3$ не верна.

Попытаемся заметить закономерности и построить догадку для $\mathbb{E}(Y_1 Y_2 Y_3 Y_4)$.

Итак,

$$\mathbb{E}(Y_1) = m_1,$$

$$\mathbb{E}(Y_1 Y_2) = m_1 m_2 + c_{12},$$

$$\mathbb{E}(Y_1 Y_2 Y_3) = m_1 c_{23} + m_2 c_{13} + m_3 c_{12} + m_1 m_2 m_3.$$

Что мы видим общего у полученных трёх формул?

Во-первых, везде в правой части только многочлены от m_i и c_{ij} . Не возникают ни дроби, ни корни, ни арксинусы, ни тангенсы, ни прочие ужасные функции. Это немножко ожидаемо, если вспомнить про размерности величин. Скажем, если Y_1 измеряется в килограммах, Y_2 — в сантиметрах, а Y_3 — в литрах, то величина $\mathbb{E}(Y_1 Y_2 Y_3)$ обязана измеряться в $\text{кг} \cdot \text{см} \cdot \text{л}$. И слагаемое вида $\frac{m_1^3}{c_{23}}$

невозможно в силу того, что измеряется в $\frac{\text{кг}^3}{\text{см} \cdot \text{л}}$. Напомним, что c_{23} измеряется в $\text{кг} \cdot \text{л}$. Впрочем, соображения размерностей не исключают слагаемых вида $m_2 c_{12} \frac{c_{23}}{c_{22}}$.

Во-вторых, нигде не участвуют дисперсии. Я не знаю интуитивного аргумента, почему бы дисперсиям там не оказаться.

В-третьих, все коэффициенты многочлена в правой части формулы равны единице. Соображения симметрии, конечно, гарантируют нам, что должны быть равны коэффициенты при слагаемых $m_1 c_{23}$ и $m_2 c_{13}$. Но здесь равны все коэффициенты и более того, равны единице.

В-четвертых, в правой части можно найти все возможные одночлены, где упомянуты ровно по одному разу все индексы левой части. Например, для $\mathbb{E}(Y_1 Y_2 Y_3)$ правая часть содержит все возможные слагаемые с одной единицей, одной двойкой и одной тройкой в индексе.

Если предположить, что все эти подмеченные особенности сохраняются дальше, то искомое ожидание $\mathbb{E}(Y_1 Y_2 Y_3 Y_4)$ обязано равняться,

$$\begin{aligned} \mathbb{E}(Y_1 Y_2 Y_3 Y_4) = & m_1 m_2 m_3 m_4 + \\ & + m_1 m_2 c_{34} + m_1 m_3 c_{14} + m_1 m_4 c_{23} + m_2 m_3 c_{14} + m_2 m_4 c_{13} + m_3 m_4 c_{12} + \\ & + c_{12} c_{34} + c_{13} c_{24} + c_{14} c_{23}. \end{aligned}$$

И это оказывается верно! Давайте сформулируем теорему Иссерлиса. По моему мнению, проще сформулировать её текстом, чем формулой.

Theorem 1 (“Теорема Иссерлиса”)

Если вектор Y имеет многомерное нормальное распределение $\text{Norm}(m, C)$, то ожидание $\mathbb{E}(Y_1 Y_2 \dots Y_n)$ является суммой всех возможных произведений ожиданий (m_i) и ковариаций (c_{ij}) , в которых каждый индекс от 1 до n упомянут ровно один раз. Для примера,

$$\begin{aligned} \mathbb{E}(Y_1) &= m_1, \\ \mathbb{E}(Y_1 Y_2) &= m_1 m_2 + c_{12}, \\ \mathbb{E}(Y_1 Y_2 Y_3) &= m_1 c_{23} + m_2 c_{13} + m_3 c_{12} + m_1 m_2 m_3, \\ \mathbb{E}(Y_1 Y_2 Y_3 Y_4) &= m_1 m_2 m_3 m_4 + \\ & + m_1 m_2 c_{34} + m_1 m_3 c_{14} + m_1 m_4 c_{23} + m_2 m_3 c_{14} + m_2 m_4 c_{13} + m_3 m_4 c_{12} + \\ & + c_{12} c_{34} + c_{13} c_{24} + c_{14} c_{23}. \end{aligned} \tag{4}$$

Доказательство через добавление помех. Многомерное нормальное распределение полностью определяется вектором ожиданий m и ковариационной матрицей C , поэтому $\mathbb{E}(Y_1 Y_2 \dots Y_n)$ должно быть функцией от m и C ,

$$\mathbb{E}(Y_1 Y_2 \dots Y_n) = h(m, C). \tag{5}$$

Переход к центрированным величинам, $Y_i = m_i + X_i$, и раскрытие скобок показывает, что функция $h()$ является многочленом относительно переменных $m_1, m_2, \dots, m_n$. Например, для трёх переменных,

$$\begin{aligned}\mathbb{E}(Y_1 Y_2 Y_3) &= \mathbb{E}((m_1 + X_1)(m_2 + X_2)(m_3 + X_3)) = \\ &= m_1 \mathbb{E}(X_2 X_3) + m_2 \mathbb{E}(X_1 X_3) + m_3 \mathbb{E}(X_1 X_2) + m_1 m_2 \mathbb{E}(X_3) + m_1 \mathbb{E}(X_2) m_3 + m_2 \mathbb{E}(X_1) m_3 + \\ &\quad + m_1 m_2 m_3 + \mathbb{E}(X_1 X_2 X_3).\end{aligned}$$

Докажем теперь, что от дисперсий c_{ii} ожидание $h(m, C)$ не зависит. Для этого прибавим к первой величине Y_1 помеху tW , где W — стандартная нормальная величина, $W \sim \text{Norm}(0, 1)$, независимую ни от одной из величин $Y_1, Y_2, \dots, Y_n$.

$$\begin{aligned}\mathbb{E}((Y_1 + tW)Y_2 \cdot \dots \cdot Y_n) &= \mathbb{E}(Y_1 Y_2 \cdot \dots \cdot Y_n) + t\mathbb{E}(W \cdot Y_2 \cdot \dots \cdot Y_n) = \\ &= \mathbb{E}(Y_1 Y_2 \cdot \dots \cdot Y_n) + t\mathbb{E}(W)\mathbb{E}(Y_2 \cdot \dots \cdot Y_n).\end{aligned}\tag{7}$$

Ожидание $\mathbb{E}(W)$ равно нулю, поэтому выходит, что прибавление помехи не повлияло на значение искомого ожидания. Однако прибавление помехи tW к величине Y_1 увеличивает дисперсию первого элемента вектора, не трогая ожидания (m_i) и остальные элементы ковариационной матрицы C . Следовательно, изменение дисперсии никак не влияет на итоговое значение ожидания $h(m, C)$.

Теперь докажем, что $h(m, C)$ является многочленом от каждой ковариации (c_{ij}) . Для этого прибавим помеху tW к **двум** первым величинам,

$$\begin{aligned}\mathbb{E}((Y_1 + tW)(Y_2 + tW)Y_3 \cdot \dots \cdot Y_n) &= \mathbb{E}(Y_1 Y_2 Y_3 \cdot \dots \cdot Y_n) + t^2 \mathbb{E}(W^2) \mathbb{E}(Y_3 Y_4 \cdot \dots \cdot Y_n) + \\ &\quad + t\mathbb{E}(W)\mathbb{E}(Y_1 Y_3 \cdot \dots \cdot Y_n) + t\mathbb{E}(W)\mathbb{E}(Y_2 Y_3 \cdot \dots \cdot Y_n).\end{aligned}\tag{8}$$

В силу того, что $W \sim \text{Norm}(0, 1)$ можем подставить ожидание $\mathbb{E}(W) = 0$ и дисперсию $\text{Var}(W) = \mathbb{E}(W^2) = 1$,

$$\mathbb{E}((Y_1 + tW)(Y_2 + tW)Y_3 \cdot \dots \cdot Y_n) = \mathbb{E}(Y_1 Y_2 Y_3 \cdot \dots \cdot Y_n) + t^2 \mathbb{E}(Y_3 Y_4 \cdot \dots \cdot Y_n).$$

Внесение помехи не влияет на вектор ожиданий m и добавляет ровно величину t^2 в ковариацию c_{12} ,

$$\text{Cov}(Y_1 + tW, Y_2 + tW) = \text{Cov}(Y_1, Y_2) + t \cdot 0 + t \cdot 0 + t^2 \cdot 1. \tag{10}$$

Следовательно, зависимость функции $h(m, C)$ от ковариации c_{12} между первыми двумя величинами Y_1 и Y_2 линейная. Остальные ковариации ничем не лучше и не хуже :)

К этому моменту мы доказали, что искомая функция $h(m, C)$ является многочленом от ожиданий (m_i) и ковариаций (c_{ij}) . Остаётся доказать, что все нужные одночлены, где каждый нижний индекс упомянут ровно один раз, присутствуют с коэффициентом 1, а все лишние одночлены — полностью отсутствуют.

Покажем охоту за коэффициентами многочлена на примере :)

Как найти коэффициент при одночлене $m_1 c_{23} c_{45}$ в многочлене $\mathbb{E}(Y_1 Y_2 Y_3 Y_4 Y_5)$?

Мы просто занулим все остальные одночлены! Для этого возьмём Y_1 тождественно равное константе m_1 , пару стандартных нормальных величин Y_2, Y_3 , тождественно равных друг другу, $Y_2 = Y_3$, и не зависящих ни от чего другого, и пару стандартных нормальных величин Y_4, Y_5 , тождественно равных друг другу, $Y_4 = Y_5$, и не зависящих ни от чего другого. Мы специально подстроили, что все ковариации c_{ij} равны 0 кроме $c_{23} = 1$ и $c_{45} = 1$. И специально подстроили, что все ожидания m_i равны 0 кроме m_1 . Тем самым мы оставили в многочлене только нужный одночлен с неизвестным коэффициентом k спереди!

$$\mathbb{E}(Y_1 Y_2 Y_3 Y_4 Y_5) = k m_1 c_{23} c_{45}. \quad (11)$$

В силу того, что $m_1 = 1, c_{23} = 1, c_{45} = 1$, правая часть равна k . Левая часть равна

$$\mathbb{E}(Y_1 Y_2 Y_3 Y_4 Y_5) = \mathbb{E}(Y_1 Y_2^2 Y_4^2) = \mathbb{E}(Y_1) \mathbb{E}(Y_2^2) \mathbb{E}(Y_4^2) = 1 \cdot 1 \cdot 1. \quad (12)$$

Отсюда искомый коэффициент k перед одночленом равен $k = 1$.

Дотошный читатель может возразить, что полно других многочленов, дающих нужное единичное ожидание $\mathbb{E}(Y_1 Y_2 Y_3 Y_4 Y_5)$, например,

$$\mathbb{E}(Y_1 Y_2 Y_3 Y_4 Y_5) = 0.5 m_1^3 c_{23}^7 c_{45}^7 + 0.5 m_1 c_{23}^2 c_{45}^3. \quad (13)$$

От таких многочленов нас спасают соображения размерности. В предложенном контр-примере размерность левой и правой части не совпадает. Скажем, если все Y_i измеряются в килограммах, то левая часть измеряется в $(\text{кг})^5$, а в правой части даже не получится сложить два слагаемых $0.5(\text{кг})^{11} + 0.5(\text{кг})^6$. Также от гипотетической возможности многочленов с повтором какого-то нижнего индекса i можно избавиться, мысленно увеличив соответствующую величину Y_i в t раз. При таком изменении искомое ожидание $h(m, C)$ должно увеличиться в t раз, значит каждый индекс должен быть упомянут в каждом одночлене ровно один раз.

□

Bibliography

- [1] J. F. W. Herschel, “On the Theory of Probabilities,” *Journal of the Institute of Actuaries and Assurance Magazine*, vol. 15, pp. 179–218, 1869, [Online]. Available: https://www.informationphilosopher.com/solutions/scientists/quetelet/Herschel_Quetelet_Probabilities.pdf